

**UNIVERSIDADE ESTADUAL PAULISTA**  
**“JÚLIO DE MESQUITA FILHO”**  
Câmpus de Jaboticabal - SP

JOÃO TREVIZOLI ESTEVES

**CLIMATE AND AGROMETEOROLOGY FORECASTING  
USING SOFT COMPUTING TECHNIQUES.**

Jaboticabal - SP  
2018

João Trevizoli Esteves

# **CLIMATE AND AGROMETEOROLOGY FORECASTING USING SOFT COMPUTING TECHNIQUES.**

Tese apresentada à Faculdade de Faculdade de Ciências Agrárias e Veterinárias do Câmpus de Jaboticabal - UNESP como parte dos requisitos para obtenção do título de Mestre em Produção Vegetal.  
Especialidade: Automação.

Prof. Dr. Glauco Rolim  
Orientador  
Prof. Dr. Antônio Sérgio Ferraudó  
Co-orientador

Jaboticabal - SP

2018

## FICHA CATALOGRÁFICA

Elaborada pela Seção Técnica de Aquisição e Tratamento da Informação  
Serviço Técnico de Biblioteca e Documentação da UNESP - Ilha Solteira.

S235p Santim, Máira Peres Alves.  
Projeto e implementação com chaveamento de reguladores fuzzy takagi-sugeno para um conjunto de pontos de operação / Máira Peres Alves Santim. - Ilha Solteira : [s.n.], 2012  
84 f.:il.

Dissertação (mestrado) - Universidade Estadual Paulista. Faculdade de Engenharia de Ilha Solteira. Área de Conhecimento: Automação, 2012

Orientador: Marcelo Carvalho Minhoto Teixeira  
Co-orientador: Rodrigo Cardim  
Inclui bibliografia

1. Modelos fuzzy Takagi-Sugeno. 2. Desigualdades matriciais lineares (LMIs). 3. Sistemas chaveados. 4. Controlador chaveado. 5. Rastreamento.

*À minha família, em especial aos meus pais Francisco e Marilena, aos meus irmãos Rafael e Gisele e ao meu marido Ricardo, por todo amor, apoio, confiança e incentivo em todos os momentos.*

## **AGRADECIMENTOS**

Meus agradecimentos a todos os familiares, amigos, professores e funcionários da FEIS-UNESP, que direta ou indiretamente contribuíram para a realização deste trabalho. Em especial, dedico meus agradecimentos:

- A Deus, por ter me dado força e saúde para chegar até aqui;
- Aos meus pais Maria e João e aos meus irmãos Pedro e Paulo pelo carinho, apoio e incentivo;
- Ao meu marido Ricardo pelo amor, apoio, confiança e incentivo em todos os momentos;
- Ao Prof. Dr. Fulano de Tal, por todo ensinamento, incentivo, confiança e orientação;
- Ao Prof. Dr. Ciclano de Tal, pelo acompanhamento nas bancas examinadoras, sugestões e incentivo;
- Ao Dr. Beltrano pela co-orientação e todo o ensinamento.
- Aos meus amigos e colegas do laboratório que de forma direta ou indiretamente me ajudaram, em especial ao Chico, pela ajuda e o trabalho feito em conjunto ;
- Ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) pela oportunidade e apoio financeiro.

*“A vingança nunca é plena,”*

*mata a alma e a envenena.*

***Colorado, Chapolin***

## **RESUMO**

Neste trabalho foi desenvolvido uma interface gráfica para uso via web, utilizando-se as linguagens shell-script e PHP, com o objetivo de facilitar a configuração e monitoração de diferentes serviços necessários em um servidor de rede, tais como: firewall, DHCP, squid/proxy, DNS, e-mail, dentre outros. Para isso, utilizou-se uma estratégia de desenvolvimento modular, para facilidade de uso e que permite a inclusão de novos módulos posteriormente. A ferramenta foi totalmente desenvolvida com software livre e o acesso ao seu código permite alterações de acordo com as necessidades do usuário.

**Palavras-chave:** Servidores. Redes. Firewall. Segurança.

## ABSTRACT

Precipitation, in short periods of time, is a phenomenon associated with high levels of uncertainty and variability. Given its nature, traditional forecasting techniques are expensive and computationally demanding. This paper presents a soft computing technique to forecast the occurrence of rainfall in short ranges of time by Artificial Neural Networks(ANNs) in accumulated periods from 3 to 7 days for each climatic season, mitigating the necessity of predicting its amount. With this premise it is intended to reduce the variance, rise the bias of data and lower the responsibility of the model acting as a filter for quantitative models by removing subsequent occurrences of zeros values of rainfall which leads to bias the and reduces its performance. The model were developed with time series from 10 agriculturally relevant regions in Brazil, these places are the ones with the longest available weather time series and and more deficient in accurate climate predictions, it was available 60 years of daily mean air temperature and accumulated precipitation which were used to estimate the potential evapotranspiration and water balance; these were the variables used as inputs for the ANNs models. The mean accuracy of the model for all the accumulated periods were 78% on summer, 71% on winter 62% on spring and 56% on autumn, it was identified that the effect of continentality, the effect of altitude and the volume of normal precipitation, have an direct impact on the accuracy of the ANNs. The models have peak performance in well defined seasons, but loses its accuracy in transitional seasons and places under influence of macro-climatic and mesoclimatic effects, which indicates that this technique can be used to indicate the eminence of rainfall with some limitations

**Keywords:** artificial neural networks. rainfall forecasting. multilayer perceptron



## LISTA DE FIGURAS

Figure 1	Weather stations locations . . . . .	20
----------	--------------------------------------	----

## LISTA DE TABELAS

Tabela 1	Geographical locations of Brazilian ground-based conventional weather stations . . . . .	20
Tabela 2	Resultado para o sistema IEEE de 24 barras considerando alocações de elementos sugeridos pelo operador do sistema . . . . .	23
Tabela 3	Espaço de busca combinatório reduzido ( <i>EBCR</i> ) de 10, 5, 3 e 2 soluções com <i>gap</i> de 5% Para IEEE . . . . .	31

## **LISTA DE ABREVIACES E SIGLAS**

LMI	Linear Matrix Inequalities
CDP	Compensaco Distribuída Paralela
TS	Takagi-Sugeno

## LISTA DE SÍMBOLOS

$\theta_i$	Ângulo de fase na barra $i$
$g_{ij}$	Condutância da linha no ramo $ij$
$Y$	Conjunto das linhas que podem ou não serem adicionadas no ramo $ij$
$\Omega_b$	Conjunto de barras
$\Omega_l^1$	Conjunto de caminhos nos quais existem Linhas na configuração base
$\Omega_l^2$	Conjunto de caminhos novos (onde serão adicionadas novas Linhas)
$\Omega_l^0$	Conjunto de linhas existentes na configuração base
$\Omega_l$	Conjunto de ramos
$c_{ij}^n$	Custo de construção das linhas no ramo $ij$
$d_i$	Demanda na barra $i$
$\varepsilon_f$	Error da condição de factibilidade
$\varepsilon_o$	Error da condição de otimalidade
$\varepsilon_\mu$	Error do parâmetro de barreira
$\gamma$	Fator de segurança
$\bar{f}_{ij}^0$	Fluxo de potência ativa máximo nos ramos para o conjunto de linhas já existentes
$\bar{f}_{ij}^1$	Fluxo de potência ativa máximo nos ramos para o conjunto de linhas já existentes ou linhas adicionadas em paralelo
$\bar{f}_{ij}^2$	Fluxo de potência ativa máximo nos ramos para o conjunto de linhas correspondentes aos novos caminhos
$\bar{f}_{ij}$	Fluxo de potência ativa máximo permitida no ramo $ij$ para linhas novas
$f_{ij}^0$	Fluxo de potência ativa nos ramos para o conjunto de linhas já existentes
$f_{ij}^1$	Fluxo de potência ativa nos ramos para o conjunto de linhas já existentes ou linhas adicionadas em paralelo
$f_{ij}^2$	Fluxo de potência ativa nos ramos do conjunto de linhas correspondentes aos novos caminhos
$f_{ij}$	Fluxo de potência ativa no ramo $ij$ para linhas novas
$f_{ij,y}$	Fluxo na linha $y$ do ramo $ij$
$p_i$	Geração na barra $i$
$\bar{p}_i$	Geração máxima na barra $i$
$v$	Investimento devido às adições de Linhas no sistema - Função Objetivo
$ij$	Linha entre as barras $i$ e $j$
$n_{ij}$	Número de linhas adicionadas no ramo $ij$

$\bar{n}_{ij}^2$	Número máximo de linhas em caminhos novos
$\bar{n}_{ij}^1$	Número máximo de linhas que podem ser adicionadas em paralelo às linhas dos caminhos já existentes
$\bar{n}_{ij}$	Número máximo de Linhas que podem ser adicionados no ramo $ij$
$n_{ij}^1$	Número de linhas adicionadas em paralelo às linhas já existentes
$n_{ij}^0$	Número de linhas existentes na configuração base no ramo $ij$
$n_{ij}^2$	Número de linhas novas adicionadas no ramo $ij$
$\gamma_{ij}$	Susceptância nas linhas do ramo $ij$
$\gamma_{ij}^0$	Susceptância nas linhas existente do ramo $ij$
$w_{ij,y}$	Variável binária correspondente à linha $y$ candidata a ser adicionada ou não no ramo $ij$
$x_{ij}$	reatância do circuito $ij$
$q_i$	vetor de geração de potência reativa na barra $i$
$\bar{q}_i$	limite máximo de geração de potência reativa na barra $i$
$\underline{q}_i$	limite mínimo de geração de potência reativa na barra $i$
$e_i$	vetor de demanda de potência reativa na barra $i$
$V_i$	magnitude de tensão na barra $i$
$\bar{V}_i$	limite máximo da magnitude de tensão na barra $i$
$\underline{V}_i$	limite mínimo da magnitude de tensão na barra $i$
$e_i$	vetor de demanda de potência reativa na barra $i$
$s_{ij}^{de}$	fluxo de potência aparente (MVA) no ramo $ij$ saindo do terminal
$s_{ij}^{para}$	fluxo de potência aparente (MVA) no ramo $ij$ chegando no terminal
$\bar{s}_{ij}$	limite de fluxo de potência aparente (MVA) no ramo $ij$
$\theta_{ij}$	diferença angular entre as barra $i$ e $j$
$\Omega_{bi}$	conjunto das barras vizinhas da barra $i$
$g_{ij}$	condutância da linha no ramo $ij$
$g_{ij}^0$	condutância existente da linha no ramo $ij$
$b_{ij}$	susceptância da linha no ramo $ij$
$b_{ij}^{sh}$	susceptância shunt da linha no ramo $ij$
$b_i^{sh}$	susceptância shunt na barra $i$
$G_{ij}$	matriz de condutância
$B_{ij}$	matriz de susceptância

## SUMÁRIO

<b>1</b>	<b>Introduction</b>	<b>16</b>
<b>2</b>	<b>Material an Methods</b>	<b>19</b>
2.1	Dataset	19
2.2	HISTÓRICO DO LINUX	19
<b>2.2.1</b>	<b>Ações</b>	<b>20</b>
<i>2.2.1.1</i>	<i>No Atual Momento</i>	<i>20</i>
<b>3</b>	<b>SERVIDORES LINUX</b>	<b>23</b>
<b>3.0.1</b>	<b>Anexando Documentos</b>	<b>23</b>
<i>3.0.1.1</i>	<i>Documento Formulário</i>	<i>23</i>
<b>4</b>	<b>NOVO CAPÍTULO...</b>	<b>25</b>
<b>5</b>	<b>RESULTADOS E DISCUSSÕES</b>	<b>26</b>
<b>6</b>	<b>CONCLUSÕES</b>	<b>27</b>
	<b>REFERÊNCIAS</b>	<b>28</b>
	<b>APÊNDICE A - LINUX</b>	<b>30</b>
	APÊNDICE A.1 - HISTÓRICO DO LINUX	30
	<b>APÊNDICE B - AINDA FALANDO DO LINUX</b>	<b>31</b>
	APÊNDICE B.1 - MELHORIAS PARA O LINUX EM UM AMBIENTE CO- ORPORATIVOS DE DUAS GRNDES FRNTES INTERPRETATIVAS	31
	<b>ÍNDICE REMISSIVO</b>	<b>33</b>

## 1 INTRODUCTION

Water is essential for all human activities and agriculture is the largest freshwater consumer. Precipitation a phenomenon highly susceptible to variability, determines its availability(CALZADILLA et al., 2013). Research and apply accurate statistical models to forecast this phenomena has been acknowledged to play a key role for this sector of the human activity(TOTH; BRATH; MONTANARI, 2000). Given the uncertainty and variability that drives its occurrence, it is recognised that is quite difficult to obtain reliable and accurate prediction models that can spatially forecast this element of the hydrological cycle for short periods of time. (BRATH, 1997).

The precipitation forecasting problem is commonly approached in different ways. The use of remote sensing observation with radars and satellite images addresses the issue based on the extrapolation of current weather condition, for very short term forecasting (scale of minutes). Unfortunately the use of radar and satellite images do not provide a satisfactory assessment of rain intensities in larger scales of time, in addition, using this technique in mountainous regions is difficult because of the occurrence of soil shading and the altitude effect(TOTH; BRATH; MONTANARI, 2000).

One other mean to obtain rainfall forecasting models is by time series analyses techniques. There are different approaches to time series forecasting, specially for climatic proposes.Traditionally forecasting has long been the domain of linear statistics, usual approaches to time series prediction, such as Box-Jenkins(BOX; JENKINS; REINSEL, 1976) or ARIMA (autoregressive integrated moving average) method(PANKRATZ, 1983), considers that time series behaves as linear processes. Despite of its easy understanding and applicability it may be totally inappropriate to implement if the ongoing mechanism is subjected to an nonlinear processes (ZHANG, 2003).

In meteorology to deal with non linearity, it is generally used numerical weather prediction models (NWP) in applications such as Global Circulation Models (GCM). NWP is an initial-value problem for which initial data are not available in sufficient quantity and with sufficient accuracy, these models abstract some layers of information by discretising partial differential equations governing large scale atmospheric flow (GHIL et al., 1981). This method can active acceptable accuracy in forecasting some meteorological phenomenas but when dealing with rainfall they yet have not active it (RAMÍREZ; FERREIRA; VELHO, 2006), mainly because of the physical complexity of precipitation processes and the reduced temporal and spacial scale involved in such phenomena that numerical models cannot resolve (KULIGOWSKI; BARROS,

1998). One other drawback that NWP models such as GCM have is that they are computationally demanding and require powerful and expensive hardware to be implemented in a meteorological prediction center.

More recently researchers have been approaching such problem with artificial neural networks(ANN), this is a powerful alternative to traditional time-series modelling (ZHANG, 1998) as for NWP models. ANNs are data-driven self adaptive methods that are able to understand and solve problems of which there's not enough data or observations to use more traditional statistical models(ZHANG; PATUWO; HU, 1998), rainfall is such a phenomena and ANNs are suited and studied solution.

ANNs are a type of nonlinear model inspired by sophisticated functionalities of human brain. They are universal function approximators that can adaptively discover patterns from data, learn from experience and estimate any complex functional relationship with high accuracy(ZHANG, 1998; WANG, 2003), they mimics the brain functionalities both in knowledge acquisition through a learning process and memory by storing synaptic weights as acquired knowledge(FERRAUDO, 2014).

In the field of agriculture and applied math ANNs has been a successful tool to forecast meteorological indexes (KUMARASIRI; SONNADARA, 2006; NASSERI; ASGHARI; ABEDINI, 2008; RAMÍREZ; FERREIRA; VELHO, 2006; LUK; BALL; SHARMA, 2000; FRENCH; KRAJEWSKI; CUYKENDALL, 1992; TOTH; BRATH; MONTANARI, 2000; PARTAL; CIGIZOGLU; KAHYA, 2015). In these studies the goal was to numerically predict, with a single ANN structure, the accumulative volume of precipitation in a given scale in a future period of time. The performance of these models were very correlated to the time scale of events that ANNs had to handle. In larger scale of time, such as months, the performance of ANNs are vastly superior then in shorter periods of time. This happens because in larger periods of time the probability of some precipitation be recorded is greater, consecutively models are not biased by a big number of observations with zero precipitation (SCHOOOF; PRYOR, 2001) and in short scale of time rainfalls are dependent on small scale and unstable physical processes (KULIGOWSKI; BARROS, 1998).

The objective of this paper is to create a methodology to predict the occurrence of rainfall. This is done by constraining the complexity of the predicted events by reducing the variance and rising the bias of the time series. To achieve this objective, a structure of artificial neural networks is being proposed which identifies the signs that lead to the occurrence of rain for each climatic season in short periods of time, letting the ANNs to predict whether or not it is going to rain. The proposed model is intended to filter which days are propitious to rain, so that only the climate variables in the periods that lead to rain are used in quantitative models. With this technique quantitative models can improve its forecasting performance in shorter periods of time and consecutively becoming computationally lighter by reducing the volume of data used



in the training stage of the models.

## 2 MATERIAL AN METHODS

In this section, it is firstly described the dataset with emphasis in its composition, recovery of missing data and data transformation, important factors for the model accuracy. Secondly it is discussed the methodology for estimating potential evapotranspiration(PET), indispensable for calculus of water balance(TWB). Lastly it is described the methodology used in the Artificial Neural Networks to forecast small spacial and temporal scales, that is the goal of this paper.

### 2.1 Dataset

The raw data used to establish the training set for the forecast model consists basically of the daily mean air temperature and the accumulated precipitation, these indexes were ground measured by conventional weather stations (CWS) and were the one available for this study.

It was chosen the most relevant agriculture production regions distributed in eight Brazilian states, in these locations it was selected ten CWS and its locations are shown in Table 1. The CWS were chosen based on geographical proximity of important agricultural centres and by its operation start date, the Fig.1 illustrates its distribution across Brazilian territory. The optimal range of data chosen for training the prediction model was from 1950 to 2011, the years of 2012 to middle 2015 were not known by algorithm for testing and validation purposes ensuring the learning and generalisation capacities of the artificial neural networks. The cross validation method adopted was the holdout method, which is basically a separation of the dataset in two sets, a training set and a validation set, that the function approximator tests its outputs with unknown data, given the large set of data this is an feasible validation method(FRIEDMAN; HASTIE; TIBSHIRANI, 2001).

There was air temperature measurements missing within all local datasets, a common problem in long time series. It was necessary to infill the gaps with estimated values to maintain consistency in the training processes.

### 2.2 HISTÓRICO DO LINUX

Atualmente, ...

Segundo Machado e Maia (2007), o sistema operacional (SO), possui inúmeras funções, as quais podem ser resumidas em duas.

Tabela 1 - Geographical locations of Brazilian ground-based conventional weather stations

State	City	Maintainer	Lat(DD)	Long(DD)	Alt(m)
Paraná	Campo Mourão	INMET	- 24.05	- 52.36	616.4
Mato Grosso	Diamantino	INMET	- 14.40	- 56.45	286.3
Mato Grosso do Sul	Ivinhema	INMET	- 22.30	- 53.81	369.2
Ceará	Jaguaruana	INMET	- 4.78	- 37.76	11.7
Alagoas	Maceio	INMET	- 35.70	- 64.50	64.5
São Paulo	Presidente Prudente	INMET	- 22.11	- 51.38	435.5
	Jaboticabal	UNESP	-21.25	-48.32	626.0
	Piracicaba	USP	-22,73	-47.64	547.0
Goiás	Rio Verde	INMET	- 17.8	- 50.91	774.6
Minas Gerais	Uberaba	INMET	- 19.73	- 47.95	737.0

Figura 1 - Weather stations locations

### 2.2.1 Ações

- **Facilidade de acesso aos recursos:** consiste em ser totalmente transparente ao usuário a maneira como funciona um computador , ou seja, para um usuário não importa como um arquivo que está em um disquete será lido, mas sim que o mesmo será lido, resumindo, um usuário não precisa saber como será realizado essa ação e suas inúmeras etapas;

#### 2.2.1.1 No Atual Momento

A Figura ??, aparece na pagina ??, enquanto que a Figura ?? aparece na pagina ??

Um exemplo prático – extraído do texto original da norma NBR 10520 exatamente como estão lá – como é digitado e seu respectivo resultado:

A teleconferência permite ao indivíduo participar de um encontro nacional ou regional sem a necessidade de deixar seu local de origem. Tipos comuns de teleconferência incluem o uso da televisão, telefone e computador. Através de áudio conferência, utilizando a companhia local de telefone, um sinal de áudio pode ser emitido em um salão de qualquer dimensão (ANTONELLO; MACIEL, 2004, p. 23).

Um exemplo prático – extraído do texto original da norma NBR 10520 exatamente como estão lá – como é digitado e seu respectivo resultado:

Segundo Droms (1997, p. 23), a teleconferência permite ao indivíduo participar de um encontro nacional ou regional sem a necessidade de deixar seu local de origem. Tipos comuns de teleconferência incluem o uso da televisão, telefone e computador. Através de áudio conferência, utilizando a companhia local de telefone, um sinal de áudio pode ser emitido em um salão de qualquer dimensão.

Observe como fica o cabeçalho de um trabalho preparado para ser impresso frente e verso.  
(BOKHARI, 1995)

### 3 SERVIDORES LINUX

Neste capítulo serão tratados alguns tipos de servidores que pode ser configurado no linux através de módulos pré-instalados e configurados.

Como foi dito ...

#### 3.0.1 Anexando Documentos

Foram anexados os seguintes documentos.

##### 3.0.1.1 Documento Formulário

Atualmente com a evolução da tecnologia, ...

A tabela abaixo é uma tabela de exemplo de ...

Tabela 2 - Resultado para o sistema IEEE de 24 barras considerando alocações de elementos sugeridos pelo operador do sistema

	Estágio 1	Estágio 2	Estágio 3
Número de linhas $n_{ij}$	$n_{6-10} = 1$ $n_{7-8} = 2$ $n_{10-12} = 1$ $n_{11-13} = 1$	$n_{20-23} = 1$	$n_{1-5} = 1$ $n_{3-24} = 1$
Função Objetivo $v = 220.2860$			

Fonte: Dados da pesquisa do autor.

O documento formulário...(SONG et al., 2006).

Agora segundo Carlinhos Song et al. (2006) estamos todos no mesmo barco.

Se você tiver comentários, sugestões ou críticas referentes à classe ou aos estilos bibTeX, por favor entre em contato com o grupo abnTeX no Código Livre, através da nossa página

Dentre o que foi implementado por esta classe, destacamos

**Folha de rosto e capa** Um mecanismo semelhante ao `\maketitle` para sua folha de rosto e capa.

**Resumo e abstract** Use os ambientes `resumo` e `abstract` para a correta formatação destas partes do texto.

**Anexos e apêndices** Use os comandos `\anexo` ou `\apendice`, e depois comandos `\chapter` para gerar os títulos de anexos e apêndices. Veja seção 6 para como personalizar títulos destas partes.

**Espaçamento entrelinhas** Este item é automaticamente tratado pela classe, descrito em cosmopolita.

**Numeração das páginas** Como descrito em mandrack, a partir da folha de rosto, todas as páginas são contadas mas não numeradas, e a numeração aparece somente na parte textual. Isso é feito pela classe. Outros estilos de numeração serão discutidos na seção 5.

**Cabeçalhos de página** De acordo com a norma, a numeração da página aparece no canto superior direito de todas as páginas a partir da parte textual armagedon. Veja seção 45 para detalhes.

## **4 NOVO CAPÍTULO...**

Neste capítulo será abordado ...



## **5 RESULTADOS E DISCUSSÕES**

Neste capítulo será apresentado os resultados...

## **6 CONCLUSÕES**

Conclui-se que...

## REFERÊNCIAS

- ANTONELLO, F.; MACIEL, M. *Bandlimit*. [S.l.], 2004. Disponível em: <<http://underlinux.com.br>>. Acesso em: 10 Mar. 2012.
- BOKHARI, S. H. The linux operation system. *IEEE Computer Society*, New York, v. 28, n. 8, p. 74 – 79, Ago. 1995.
- BOX, G. E.; JENKINS, G. M.; REINSEL, G. C. Time series analysis: Forecasting and control. *San Francisco: Holdenday*, 1976.
- BRATH, A. On the role of numerical weather prediction models in real-time flood forecasting. In: *Proceedings of the International Workshop on River Basin Modeling: Management and Flood Mitigation*. [S.l.: s.n.], 1997. p. 249–259.
- CALZADILLA, A.; REHDANZ, K.; BETTS, R.; FALLOON, P.; WILTSHIRE, A.; TOL, R. S. Climate change impacts on global agriculture. *Climatic change*, Springer, v. 120, n. 1-2, p. 357–374, 2013.
- DROMS, R. *Dynamic Host Configuration Protocol*. [S.l.], 1997. Disponível em: <<http://ds.internice.net/ds/dspglinthdoc.html>>. Acesso em: 10 Mar. 2012.
- FERRAUDO, A. S. Artificial neural networks. In: *Nutritional Modelling for Pigs and Poultry*. [S.l.]: CABI, 2014. p. 88–95.
- FRENCH, M. N.; KRAJEWSKI, W. F.; CUYKENDALL, R. R. Rainfall forecasting in space and time using a neural network. *Journal of hydrology*, Elsevier, v. 137, n. 1, p. 1–31, 1992.
- FRIEDMAN, J.; HASTIE, T.; TIBSHIRANI, R. *The elements of statistical learning*. [S.l.]: Springer series in statistics New York, 2001.
- GARVER, L. L. Transmission linear programming. *IEEE Transactions on Power Apparatus and Systems*, Rio de Janeiro, PAS-29, n. 9, p. 168–197, Dec. 1970.
- GARVER, L. L. Transmission network estimation using linear programming. *IEEE Transactions on Power Apparatus and Systems*, São Paulo, PAS-89, n. 7, p. 1688–1697, Sep. 1970.
- GHIL, M.; COHN, S.; TAVANTZIS, J.; BUBE, K.; ISAACSON, E. Applications of estimation theory to numerical weather prediction. In: *Dynamic meteorology: Data assimilation methods*. [S.l.]: Springer, 1981. p. 139–224.
- KULIGOWSKI, R. J.; BARROS, A. P. Localized precipitation forecasts from a numerical weather prediction model using artificial neural networks. *Weather and forecasting*, v. 13, n. 4, p. 1194–1204, 1998.

- KUMARASIRI, A.; SONNADARA, D. Rainfall forecasting: an artificial neural network approach. In: *Proceedings of the Technical Sessions*. [S.l.: s.n.], 2006. v. 22, p. 1–13.
- LUK, K.; BALL, J.; SHARMA, A. A study of optimal model lag and spatial inputs to artificial neural network for rainfall forecasting. *Journal of Hydrology*, Elsevier, v. 227, n. 1, p. 56–65, 2000.
- MACHADO, F. B.; MAIA, L. P. *Arquitetura de Sistemas Operacionais*. 4. ed. Rio de Janeiro: LTC, 2007. 105 p. p.
- NASSERI, M.; ASGHARI, K.; ABEDINI, M. Optimized scenario for rainfall forecasting using genetic algorithm coupled with artificial neural network. *Expert Systems with Applications*, Elsevier, v. 35, n. 3, p. 1415–1421, 2008.
- PANKRATZ, A. Forecasting with univariate box-jenkins method. NY: Wiley, 1983.
- PARTAL, T.; CIGIZOGLU, H. K.; KAHYA, E. Daily precipitation predictions using three different wavelet neural network algorithms by meteorological data. *Stochastic Environmental Research and Risk Assessment*, Springer, v. 29, n. 5, p. 1317–1329, 2015.
- RAMÍREZ, M. C.; FERREIRA, N. J.; VELHO, H. F. C. Linear and nonlinear statistical downscaling for rainfall forecasting over southeastern brazil. *Weather and forecasting*, v. 21, n. 6, p. 969–989, 2006.
- SCHOOOF, J. T.; PRYOR, S. Downscaling temperature and precipitation: A comparison of regression-based methods and artificial neural networks. *International Journal of climatology*, Wiley Online Library, v. 21, n. 7, p. 773–790, 2001.
- SONG, X.; STINSON, M.; LEE, R.; ALBEE, P. An approach to analyzing the windows and linux security models. In: *COMPUTER AND INFORMATION SCIENCE, 2006 AND 2006 1st IEEE/ACIS INTERNATIONAL WORKSHOP ON COMPONENT-BASED SOFTWARE ENGINEERING, SOFTWARE ARCHITECTURE AND REUSE. ICIS-COMSAR 2006. 5th IEEE/ACIS INTERNATIONAL CONFERENCE*. [S.l.: s.n.], 2006. p. 56–62.
- TOTH, E.; BRATH, A.; MONTANARI, A. Comparison of short-term rainfall prediction models for real-time flood forecasting. *Journal of Hydrology*, Elsevier, v. 239, n. 1, p. 132–147, 2000.
- WANG, S.-C. Artificial neural network. In: *Interdisciplinary Computing in Java Programming*. [S.l.]: Springer, 2003. p. 81–100.
- ZHANG, G. *Linear and nonlinear time series forecasting with artificial neural networks*. [S.l.]: Kent State University, 1998.
- ZHANG, G.; PATUWO, B. E.; HU, M. Y. Forecasting with artificial neural networks:: The state of the art. *International journal of forecasting*, Elsevier, v. 14, n. 1, p. 35–62, 1998.
- ZHANG, G. P. Time series forecasting using a hybrid arima and neural network model. *Neurocomputing*, Elsevier, v. 50, p. 159–175, 2003.

## APÊNDICE A - LINUX

Neste capítulo será abordado o surgimento e a evolução do sistema operacional Linux. (GARVER, 1970a).

### APÊNDICE A.1 - HISTÓRICO DO LINUX

Atualmente, ...

Segundo Machado e Maia (2007), o sistema operacional (SO), possui inúmeras funções, as quais podem ser resumidas em duas:

- **Facilidade de acesso aos recursos:** consiste em ser totalmente transparente ao usuário a maneira como funciona um computador paralelo , ou seja, para um usuário não importa como um arquivo que está em um disquete será lido, mas sim que o mesmo será lido, resumindo, um usuário não precisa saber como será realizado essa ação e suas inúmeras etapas;

## APÊNDICE B - AINDA FALANDO DO LINUX

Neste capítulo será abordado o surgimento e a evolução do sistema operacional Linux.

### APÊNDICE B.1 - MELHORIAS PARA O LINUX EM UM AMBIENTE CORPORATIVOS DE DUAS GRANDES FRNTES INTERPRETATIVAS

Atualmente, ...

- **Facilidade de acesso aos recursos:** consiste em ser totalmente transparente ao usuário a maneira como funciona um computador, ou seja, para um usuário comum não importa como um arquivo que está em um disquete será lido, mas sim que o mesmo será lido, resumindo, um usuário não precisa saber como será realizado essa ação e suas inúmeras etapas. (MACHADO; MAIA, 2007);

Para facilitar a vida dos usuários, um exemplo de tabela longa.

Tabela 3 - Espaço de busca combinatório reduzido (*EBCR*) de 10, 5, 3 e 2 soluções com *gap* de 5% Para IEEE

Ramos	Número Máximo de linhas									
	poolreplace=0		poolreplace=1				poolreplace=2			
	5 sol.	2 sol.	10 sol.	5 sol.	3 sol.	2 sol.	10 sol.	5 sol.	3 sol.	2 sol.
$n_{1-2}$	3	1	3	4	2	1	4	3	2	0
$n_{1-3}$	0	0	0	0	0	0	0	0	0	0
$n_{1-5}$	1	1	1	1	1	1	1	1	1	1
$n_{2-4}$	0	0	0	0	0	0	0	0	0	0
$n_{2-6}$	0	0	0	0	0	0	0	0	0	0
$n_{3-9}$	0	0	0	0	0	0	0	0	0	0
$n_{3-24}$	1	1	1	1	1	1	1	1	1	1
$n_{4-9}$	0	0	0	0	0	0	0	0	0	0
$n_{5-10}$	0	0	0	0	0	0	0	0	0	0
$n_{6-10}$	1	1	1	1	1	1	1	1	1	1
$n_{7-8}$	3	2	3	2	3	3	2	3	2	3
$n_{8-9}$	0	0	0	0	0	0	0	0	0	0
$n_{8-10}$	0	0	0	0	0	0	0	0	0	0
$n_{9-11}$	0	0	0	0	0	0	0	0	0	0
$n_{9-12}$	0	0	0	0	0	2	0	0	0	0

*continua.*

Tabela 3 - (Continuação da tabela da página anterior)

Ramos	Número Máximo de linhas									
	poolreplace=0		poolreplace=1				poolreplace=2			
	5 sol.	2 sol.	10 sol.	5 sol.	3 sol.	2 sol.	10 sol.	5 sol.	3 sol.	2 sol.
$n_{10-11}$	1	0	1	0	1	1	0	1	0	1
$n_{10-12}$	1	1	1	1	1	1	1	1	1	1
$n_{11-13}$	1	1	1	1	1	1	1	1	1	1
$n_{11-14}$	0	0	0	0	0	1	0	0	0	0
$n_{12-13}$	0	0	0	0	0	0	0	0	0	0
$n_{12-23}$	0	0	0	0	0	0	0	0	0	0
$n_{13-23}$	0	0	0	0	0	0	0	0	0	0
$n_{14-16}$	1	1	1	1	1	1	1	1	1	1
$n_{15-16}$	0	0	0	0	0	0	0	0	0	0
$n_{15-21}$	0	0	0	0	0	0	0	0	0	0
$n_{15-24}$	0	0	0	0	0	0	0	0	0	0
$n_{16-17}$	0	0	0	0	0	0	0	0	0	0
$n_{16-19}$	0	0	0	0	0	0	0	0	0	0
$n_{17-18}$	0	0	0	0	0	0	0	0	0	0
$n_{17-22}$	0	0	0	0	0	0	0	0	0	0
$n_{18-21}$	0	0	0	0	0	0	0	0	0	0
$n_{19-20}$	0	0	0	0	0	0	0	0	0	0
$n_{20-23}$	1	1	1	1	1	1	1	1	1	1
$n_{21-22}$	0	0	0	0	0	0	0	0	0	0
$n_{1-8}$	0	0	0	0	0	0	0	0	0	0
$n_{2-8}$	0	0	0	0	0	1	0	0	0	0
$n_{6-7}$	0	0	0	0	0	2	0	0	0	0
$n_{13-14}$	0	0	0	0	0	1	0	0	0	0
$n_{14-23}$	1	0	1	0	1	1	0	1	0	1
$n_{16-23}$	0	0	0	0	0	0	0	0	0	0
$n_{19-23}$	0	0	0	0	0	0	0	0	0	0
F.O	220.28	220.28	220.28	220.28	220.28	220.28	220.28	220.28	220.2	220.2

Fonte: Dados da pesquisa do autor.

*Fim.*

**ÍNDICE REMISSIVO**

computador, 20, 30  
paralelo, 30

usuário, 30, 31  
comum, 31